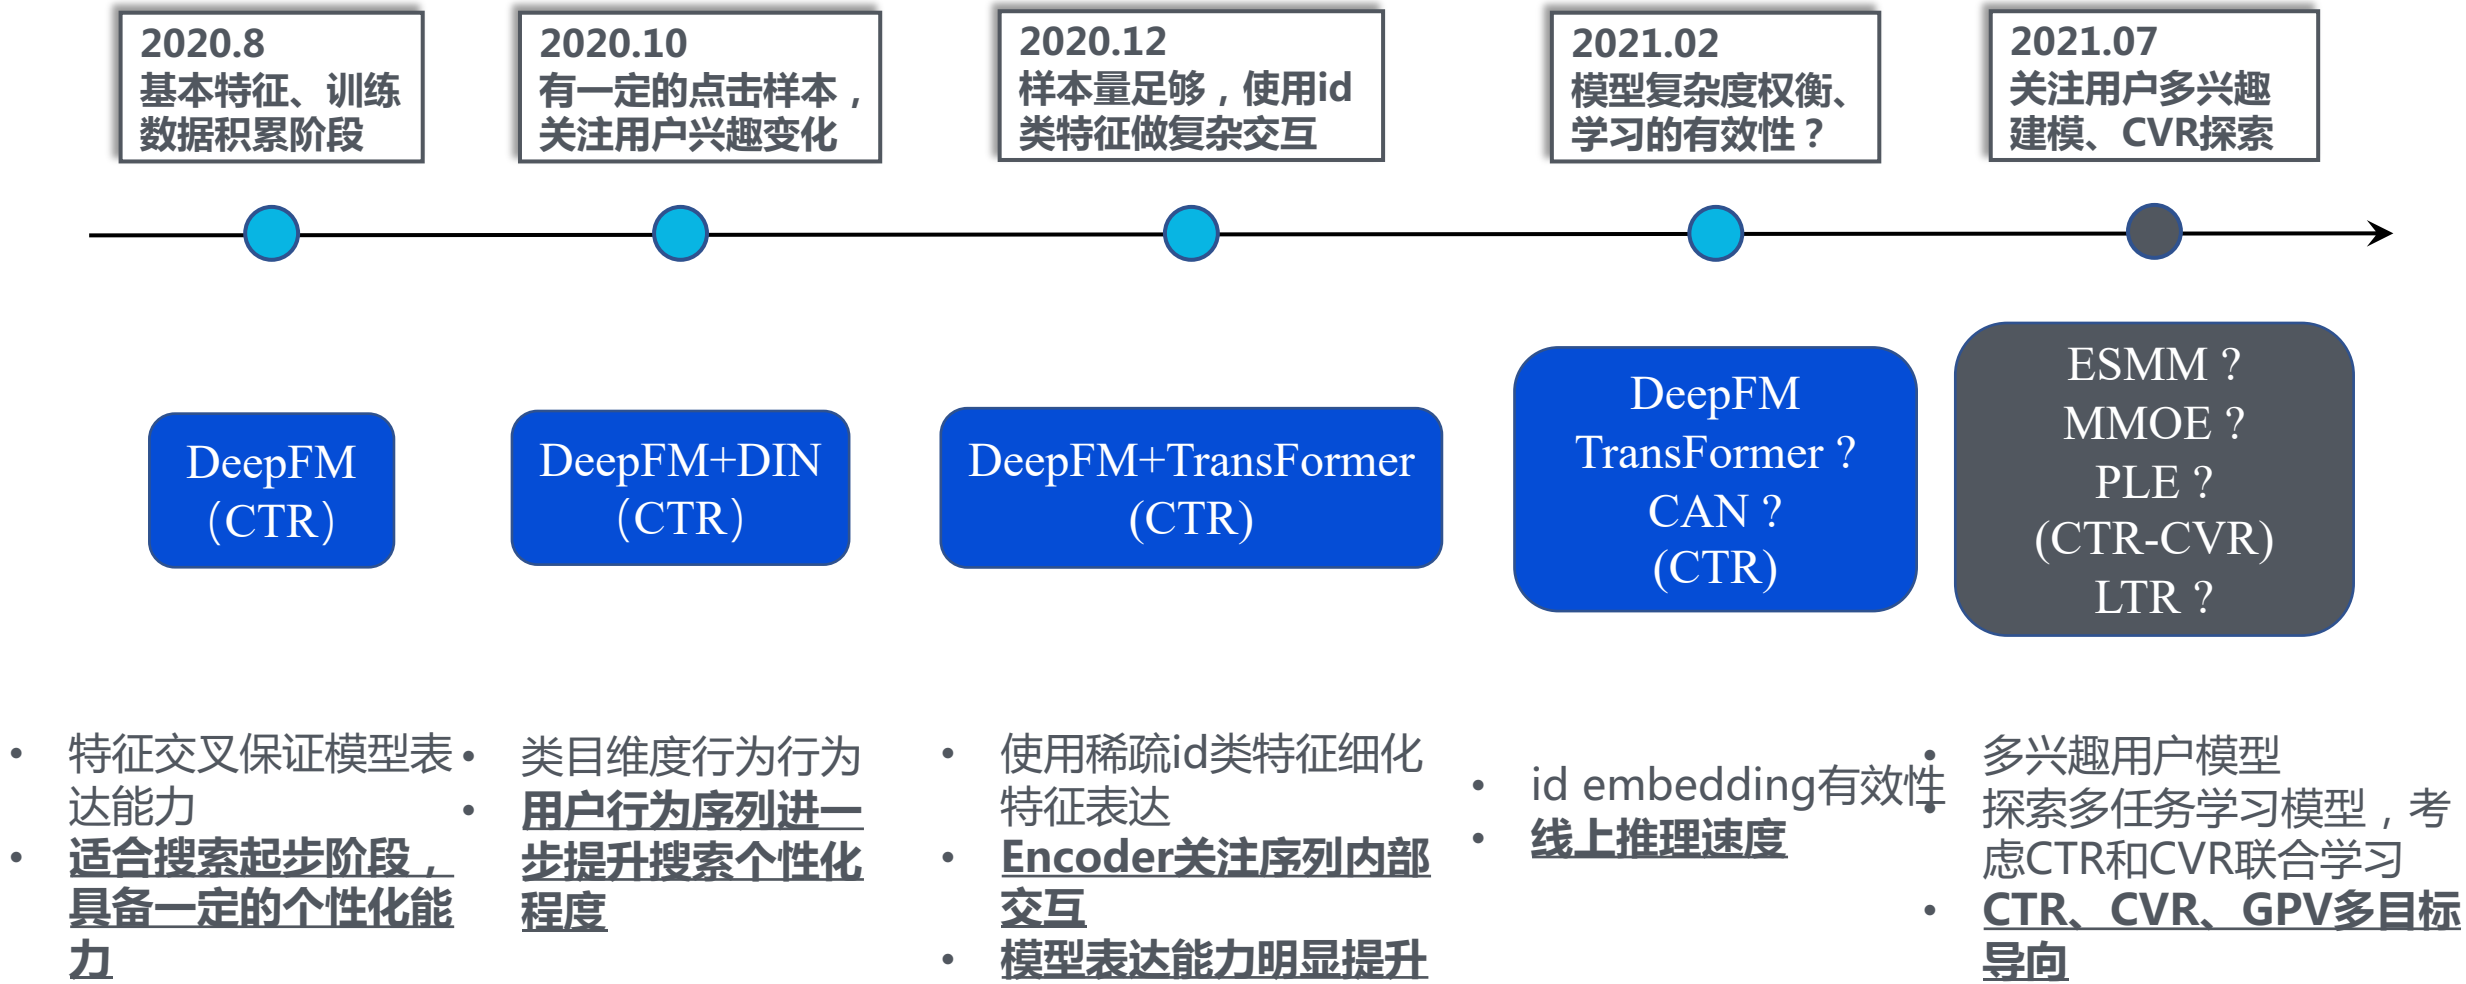



搜索排序



精排模型迭代路线图

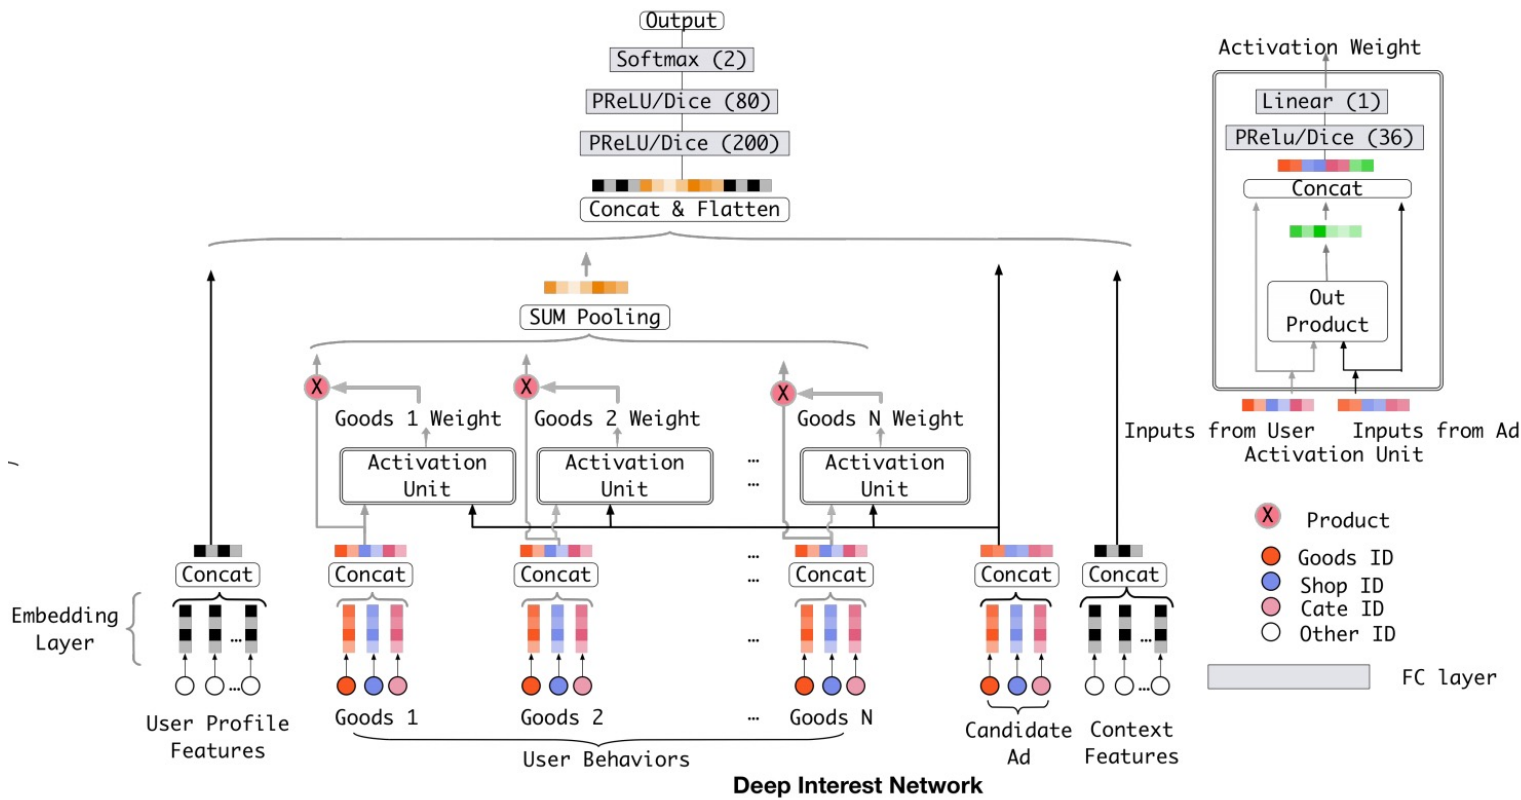


DeepFM



- 训练数据量少
- 用户行为不丰富
- Base model


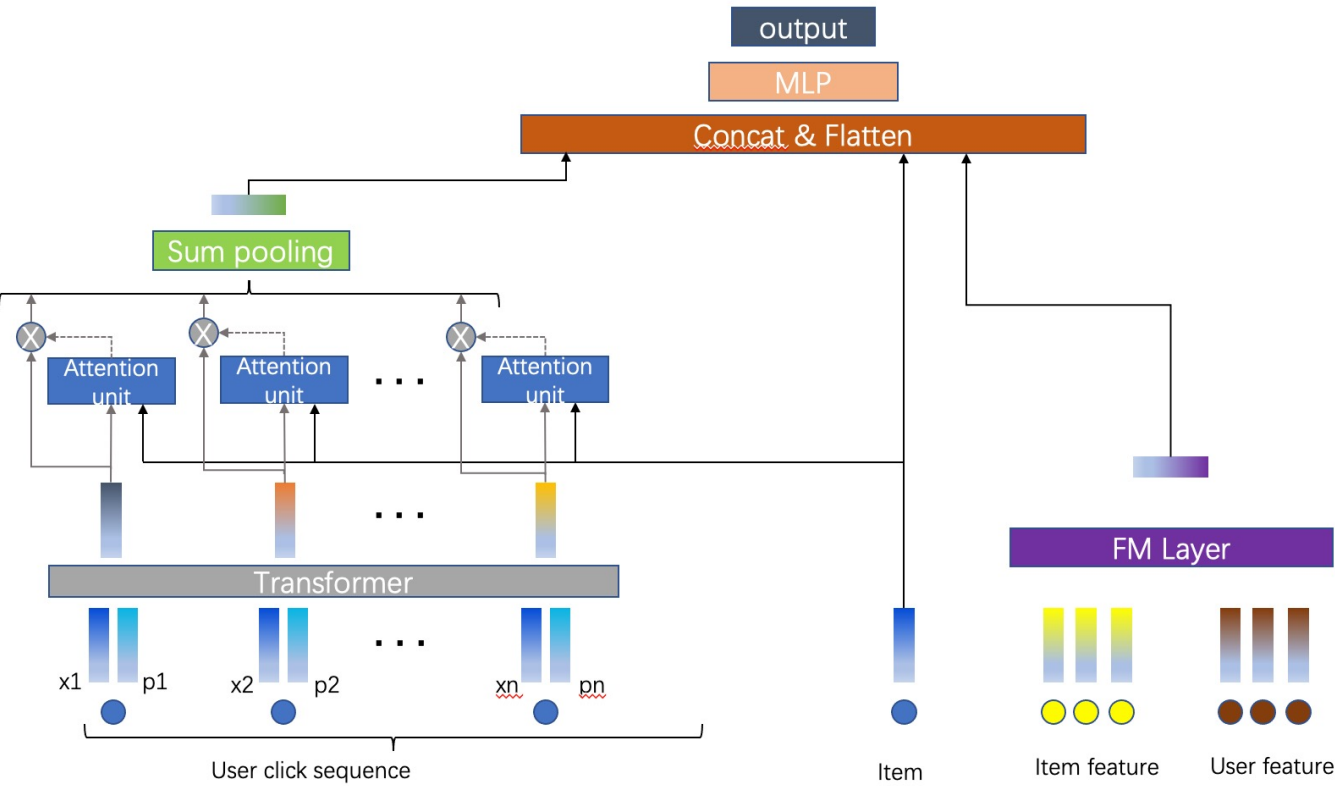
DIN



- 三级类目序列 -> 商品id序列
- 行为序列有丰富的用户兴趣表达
- pvctr + 9.81%

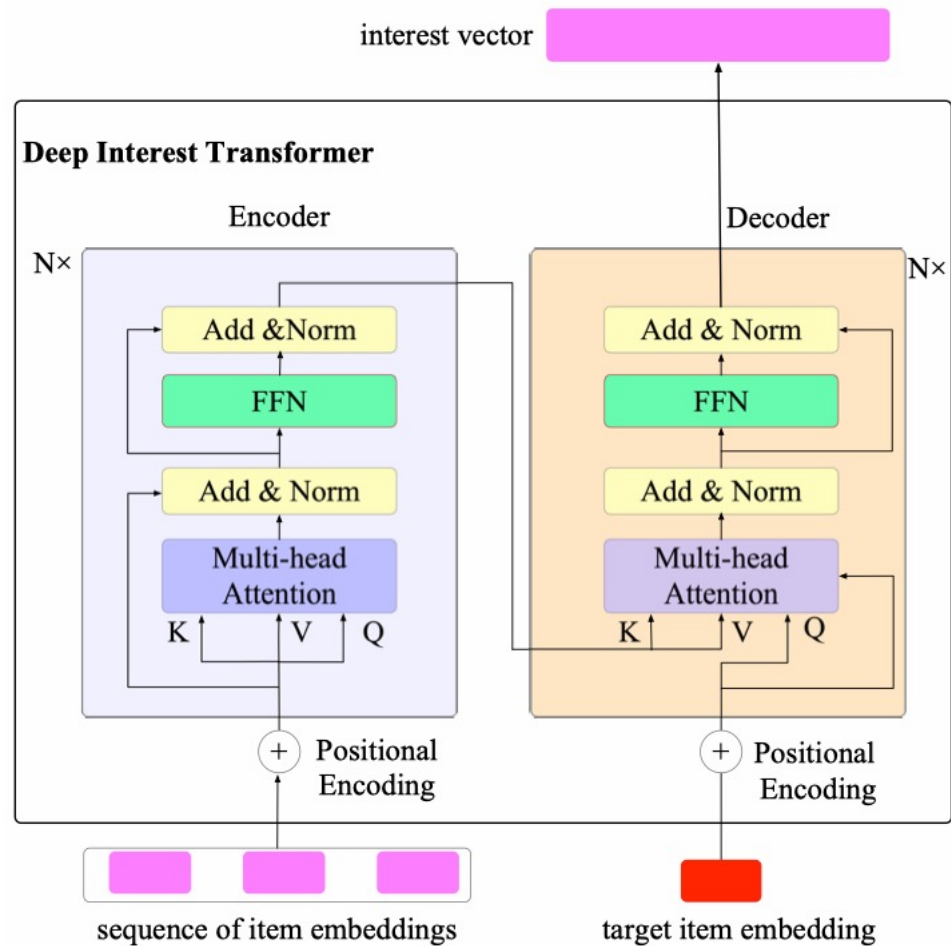
Transformer

序列内部的互相影响？ With encoder



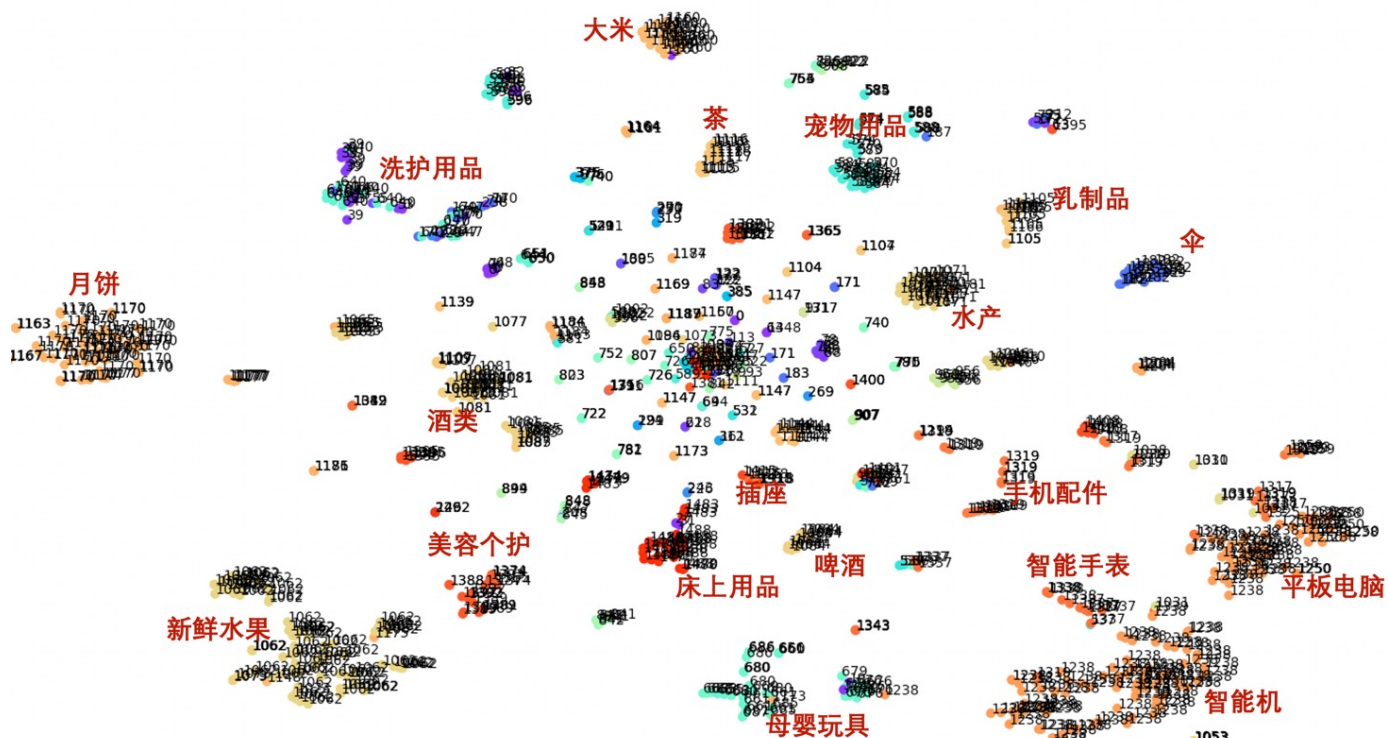
搜redmi k30
Encoder 建模序列的position + 内部交互
时间衰减效应

Transformer



- 序列对目标商品的交互？
 - ✓ Encoder + decoder
- 不同序列类型？
 1. 点击 短期偏好
 2. 成交、收藏 长期偏好

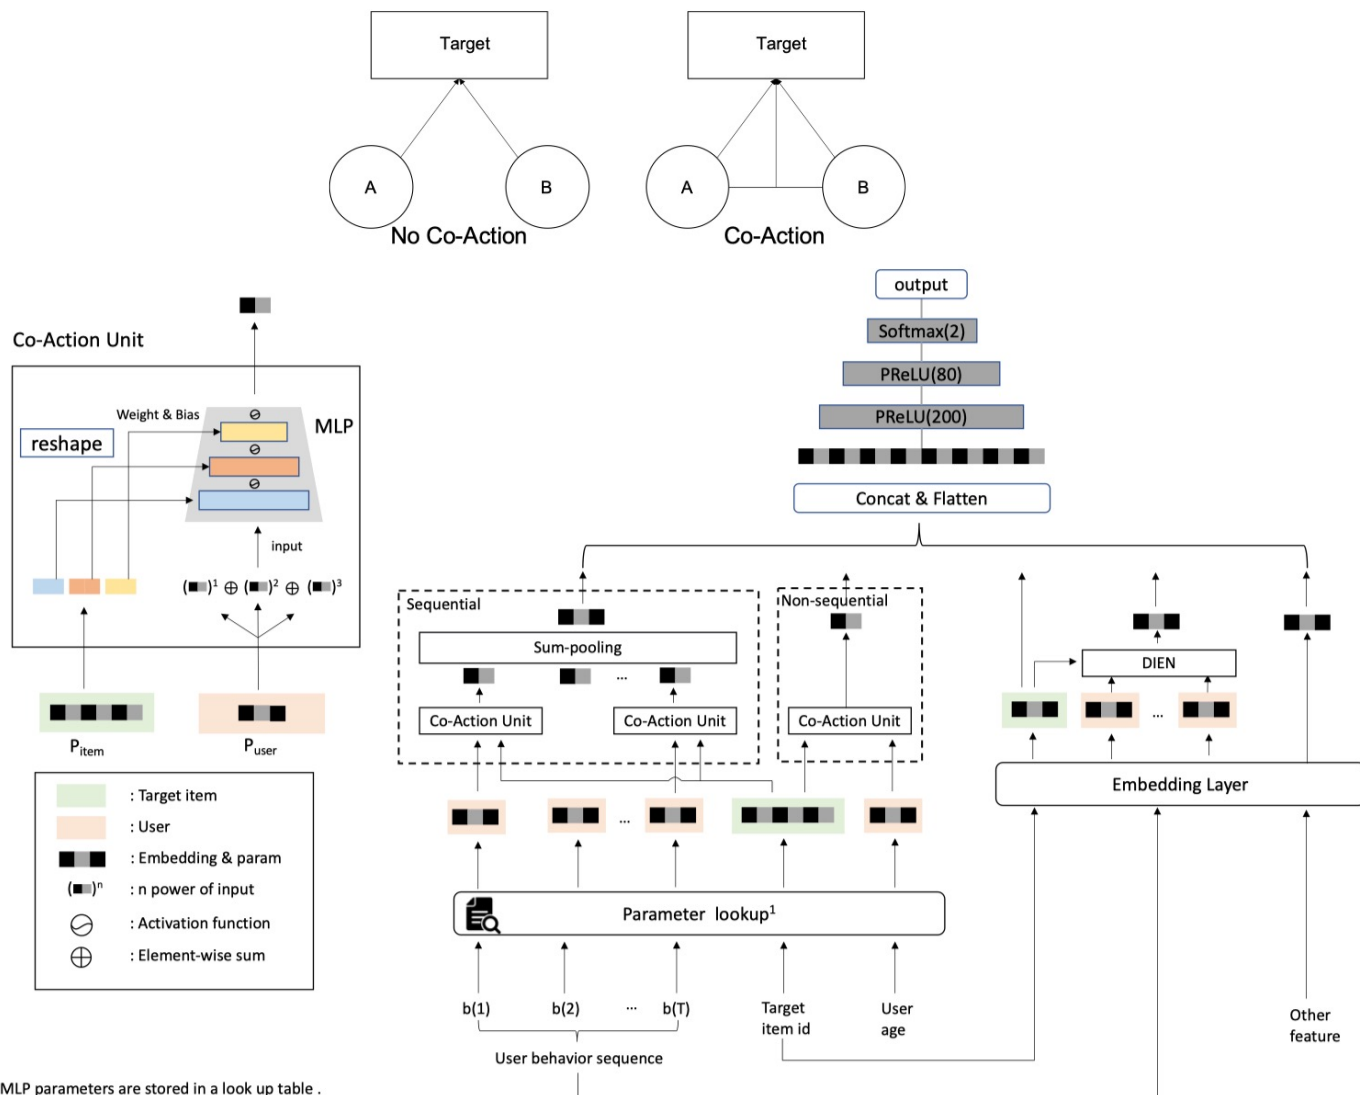
Transformer



id embedding 有效性？

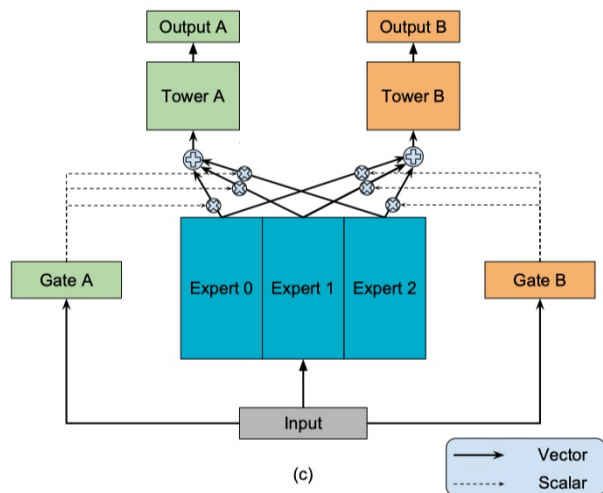
DeepFM + Encoder + Decoder
pvctr + 5.51%

CAN



- DIN类模型对序列的aggregation只是做了标量的修正
- 笛卡尔积作为新特征（数量爆炸）
- Co-action特征独立学习，自由度更高，类似一个容量巨大的记忆模型
- CAN折中，隐式交互，一端作为输入、一端作为MLP参数


多目标建模



- 样本不均衡，点击样本1.8%，购买样本0.1%
- CVR预估的问题
 - SSB问题，点击数据作为训练集，点击转化为正样本、点击未转化为负样本，inference面对整个曝光样本空间
 - 点击样本稀少，训练不充分
- 基本思路

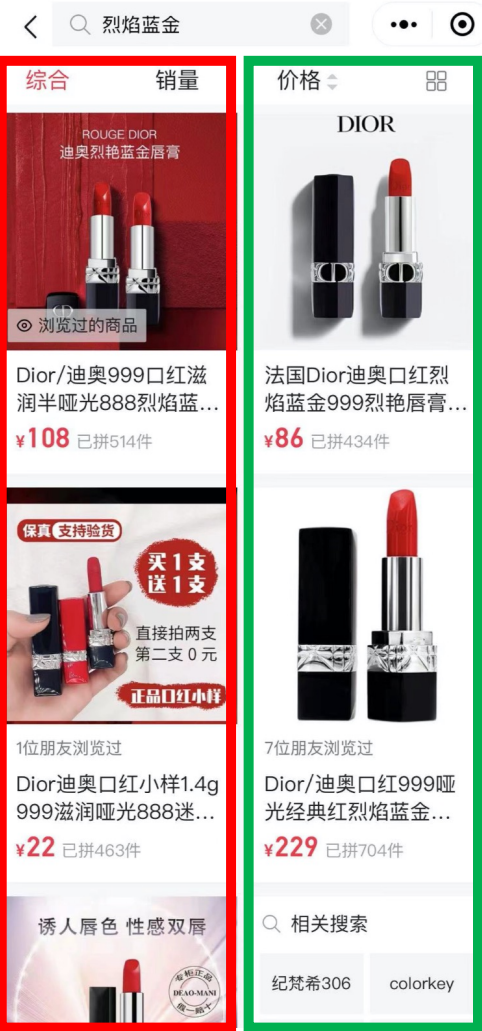
- MMOE / PLE + loss Reweight
- ESMM 预估pctr和pctcvr= $pctr * pcvr$ ，面对整个曝光样本空间，隐式得到pcvr
- 线上打分公式调整 $ctr * sigmoidCvr$

$$sigmoidCvr = \frac{1}{\alpha + e^{-\beta * cvr}}$$




Bandit

模型打分 Bandit打分



- 新品特征不足，模型难以做到准确的预估
- 强插保证曝光，独立排序，EE策略，交给用户决策
- 汤普森采样，beta分布， α =收益 β =尝试
- 一个新品作为一个臂， α =F(点击，购买)， β =F(曝光，点击，购买)，beta分布结果作为得分



- 特征精细化
- point wise -> pair wise / list wise
- 重排模型化
- 与平台目标做更紧密的结合 -> 分人群 / 分商品